

# 6.22

生成器=最优传输吗？当使用 wasserstein loss function

不同数据集代表着最优传输问题不同吗？

## 对方法细节的讨论

- 1.探讨能够度量**图片语义的空间**需要哪些性质？，提出在特征空间内有效评价语义扩充的**条件**，揭示GAN对样本特征扩充的物理本质（可解释性、物理原理），**指明了隐空间，作为一种特殊的特征空间**，具有语义表征的能力（摄影几何vs分布拟合，传统增强方法与GAN增强方法的不用）；
- 能够度量图片语义的空间需要哪些性质？隐空间是一种特殊的特征空间。
  - 隐空间，满足的性质1，性质2，性质3 -> 通过前人对隐空间性质的研究验证。
  - 隐空间具有语义表征的能力：属性编辑等。
  - 揭示GAN对样本特征扩充的物理本质：流形学习角度解释GANr如何补全特征+小实验。
- 2.分析验证GAN-like方法隐空间的性质与语义扩充评价条件，**提出对GAN-like网络建立公共隐空间的方法**（验证公共隐空间的性质），实现对不同模型特征扩征的比较；
- 通过映射，将不同的GAN生成的图片映射到低维空间。通过对假设与性质的验证，使得能够在低维空间中度量语义信息，以比较不同模型的语义扩充能力。
  - - 对于两个预训练的生成器网络A，B。
    - 寻找映射f, 以方法一中提所出的性质为目标将A，B映射到**公共中间空间W**，W是一个特征空间。
    - 在**公共中间空间W**中选择比较分布的距离。
- 3.解决了OT距离的存在性，提出评价指标的解析解，确立公共隐空间中的特征扩充评价指标（测度 metrics），量化评价不同算法扩征有效性；
- monge ampere euqtion...
  - LSFAS = IS + FID + FeatureScore

GAN 方法	隐空间的映射	对隐空间向量的操作: feature	
style-gan	LSFAS, IS, FID	LSFAS, IS, FID	
wgan	LSFAS, IS, FID	LSFAS, IS, FID	
...	LSFAS, IS, FID	LSFAS, IS, FID	

## 结果：

对不同类型的GAN网络测试了评价模型与评价指标，分析性能差异，并与传统的评价模型做对比（将验证评价指标与FID,IS等指数的关联性，例如  $SIC = FID + IS + KKKK$ ，其中KKK 代表了对语义信息的评价）。

# 结论：

探讨了能够度量语义信息的特征空间需要满足的性质，有效评价语义扩充的条件。在公共特征空间中，提出了着眼于语义信息评价数据增强效果的评价指标。指导在数据增强问题上GAN的评价与选择。

# 6.15

## 思路：数据增强 == 生成器问题 (half white box)

- 研究的重要性、必要性  
AI 技术依赖大量样本进行训练
- 样本获取是不易的、代价是高昂的
  - 样本增强对于AI算法的落地应用具有决定性意义
  - 传统数据增强方法有效、但是作用有限，遭遇技术瓶颈：
  - GAN-family 开辟了新思路，GAN-family 算法在物理、化学、生物（医药生成、蛋白质解构）、工业（无人驾驶、故障诊断）、经济 领域实现了广泛且成功的应用
  - 然而，GAN族生成式样本，存在模式坍塌和收敛性问题，增强方法机理不明，存在学术争鸣 collaborative（顾险峰几何） or adversarial（Goodfellow 统计）。原理性比较？（可解释性）
  - 因此，需要探究生成器机理（隐空间的映射问题），研究GAN族数据增强方法的功能边界、但缺乏有效量化研究方法（如FIS, IS等不能有效评价）
  - （确立了到隐空间的映射即⇔确立了GAN的生成器问题。（Bernier 势能））
  - 需要从语义信息出发，评价GAN模型的数据增强能力
  - 预期结论是xxx；所以主要从以下几个角度展开研究组织论文，section2 method，section 3 experimentation.....
  - 解决方案，如何增强语义信息

GAN 方法	隐空间的映射	对隐空间向量的操作：feature	
style-gan	LSFAS, IS, FID	LSFAS, IS, FID	
wgan	LSFAS, IS, FID	LSFAS, IS, FID	
...	LSFAS, IS, FID	LSFAS, IS, FID	

LSFAS = IS + FID + FeatureScore

remark: 在feature sapce 的流形上面补全了较多的信息

指导意见：映射方法、操作方法，都会影响LSFAS的得分

**目标-指导意义：**映射，要满足线性、解耦行，凸性：能实现不同特征对的属性编辑。操作：混合，内插，尽可能补全不完整的特征流形，不同层次的风格隐码，控制不同层次的特征。指导强大数据增强能力的GAN-based算法设计。

# 摘要

目的：探讨隐空间的性质，提出在隐空间内有效评价语义扩充的条件，揭示GAN对样本特征扩充的物理本质（可解释性、物理原理），指明了隐空间具有语义表征的能力和指标（摄影几何vs分布拟合，传统增强方法与GAN增强方法的不同），指导强大数据增强能力的GAN-based算法设计；

分析验证GAN-like方法隐空间的性质与语义扩充评价条件，提出对GAN-like网络建立公共隐空间的**方法**（验证公共隐空间的性质），实现对不同模型特征扩征的比较；

**流形学习的角度分析数据集，顾险峰 AE-OT-GAN 原理阐述 -->toy experiment(注重原理性) ->实际数据及验证**

解决了OT距离的存在性，提出评价指标的解析解，确立公共隐空间中的特征扩充评价指标（测度 metrics），量化评价不同算法扩征有效性；

结果：对不同类型的GAN网络测试了评价模型与评价指标，分析性能差异，并与传统的评价模型做对比（将验证评价指标与FID,IS等指数的关联性，例如  $SIC = FID + IS + KKKK$ ，其中KKK 代表了对语义信息的评价）。

结论：探讨了隐空间的性质与有效评价语义扩充的条件。在隐空间中，提出了着眼于语义信息评价数据增强效果的评价模型与特征扩充 评价指标。指导在数据增强问题上GAN的评价与选择。

## 数学：主要以顾险峰老师OT-GAN讲座为主线，以讲义为辅

### 对偶问题

### 傅里叶\拉格朗日变换、最有传输理论、蒙特-安培方程

顾险峰老师：

- Monge 问题：最有传输映射
- Kantorovich 对 Monge 的推广，从函数，到概率分布
- Monge，**对偶问题转换**，傅里叶transform, c-transform
- 结论：Monge - Ampere 方程

## 文献：深度学习可解释性

**问题：特征是数据集里没有的但符合流形，还是特征是既有的但是量不足imbalance.**

语义层特征的合理扩征是目标，语义合理--符合流形结构

数据是高维的 特征是低维的 低维空间满足流形学习性质可评价 对高维流形的补全是有效的

## 导论部分

---

- 问题：只强调样本增强，还是强调对抗生成式方法的有效性？  
网络与增强方法是否相同？
- 思路：  
研究的重要性、必要性  
AI 技术依赖大量样本进行训练  
→样本获取是不易的、代价是高昂的  
→样本增强对于AI算法的落地应用具有决定性意义  
→传统数据增强方法有效、但是作用有限，遭遇技术瓶颈  
→GAN-family 开辟了新思路，GAN-family 算法在物理、化学、生物（医药生成、蛋白质解构）、工业（无人驾驶、故障诊断）、经济 领域实现了广泛且成功的应用  
→然而，GAN族生成式样本增强方法机理不明，存在学术争鸣collaborative or adversarial?，如顾险峰采用OT描述对抗生成方法。  
→因此，有必要研究GAN族数据增强方法的功能边界、但缺乏量有效化研究方法（如FIS, IS等不能有效评价）  
→需要从语义信息出发，评价GAN模型的数据增强能力  
→预期结论是xxx；所以主要从以下几个角度展开研究组织论文，section2 method, section 3 experimentation.....

## 工作重点

---

### 具体问题problem formulation:

- 文献中是如何  
理论→toy experiment: the greatest interpreability → common test  
提出问题：对标 FID, IS, SSD 的局限性  
分析问题：  
解决问题的
- 哪些子问题是解决掉的，哪些是没有解决掉的。

## 文献查阅

SCI 文献从web of science中的核心数据库里查 <http://apps.webofknowledge.com/>

- 应用领域 extensive Real-World Applications
- 数学原理 顾险峰老师的文献
- 给出的GAN几何解释 <http://www.ipam.ucla.edu/abstract/?tid=15873>
- GAN类方法综述

# 导论

**目的：**着眼于特征，定义与量化评价数据增强有效性，量化评价GAN对样本特征的扩征能力。

**(缺少一个点，如何评价，需要更加具体)**

**方法：**

探讨隐空间的性质，提出在隐空间内有效评价语义扩充的**条件**，揭示GAN对样本特征扩充的物理本质（可解释性、物理原理），指明了隐空间具有语义表征的能力（摄影几何vs分布拟合，传统增强方法与GAN增强方法的不用）；

分析验证GAN-like方法隐空间的性质与语义扩充评价**条件**，提出对**GAN-like网络建立公共隐空间的方法**（验证公共隐空间的性质），实现对不同模型特征扩征的比较；

解决了OT距离的存在性，提出解评价指标的解析解，确立公共隐空间中的特征扩充评价指标（测度 metrics），量化评价不同算法扩征有效性；

结果：对不同类型的GAN网络上测试了评价模型与评价指标，分析性能差异，并与传统的评价模型做对比（将验证评价指标与FID,IS等指数的关联性，例如  $SIC = FID + IS + KKKK$ ，其中KKK 代表了对语义信息的评价）。

结论：探讨了隐空间的性质与有效评价语义扩充的条件。在隐空间中，提出了着眼于语义信息评价数据增强效果的评价模型与特征扩充 评价指标。指导在数据增强问题上GAN的评价与选择。

## 题目：Criteria on evaluation of GAN-based data augmentation

---

### 摘要

---

**目的：**着眼于特征，定义与量化评价数据增强有效性，量化评价GAN对样本特征的扩征能力。

**(缺少一个点，如何评价，需要更加具体)**

**方法：**

探讨隐空间的性质，提出在隐空间内有效评价语义扩充的**条件**，揭示GAN对样本特征扩充的物理本质（可解释性、物理原理），指明了隐空间具有语义表征的能力（摄影几何vs分布拟合，传统增强方法与GAN增强方法的不用）；

分析验证GAN-like方法隐空间的性质与语义扩充评价**条件**，提出对**GAN-like网络建立公共隐空间的方法**（验证公共隐空间的性质），实现对不同模型特征扩征的比较；

解决了OT距离的存在性，提出解评价指标的解析解，确立公共隐空间中的特征扩充评价指标（测度 metrics），量化评价不同算法扩征有效性；

结果：对不同类型的GAN网络上测试了评价模型与评价指标，分析性能差异，并与传统的评价模型做对比（将验证评价指标与FID,IS等指数的关联性，例如  $SIC = FID + IS + KKKK$ ，其中KKK 代表了对语义信息的评价）。

结论：探讨了隐空间的性质与有效评价语义扩充的条件。在隐空间中，提出了着眼于语义信息评价数据增强效果的评价模型与特征扩充 评价指标。指导在数据增强问题上GAN的选择，并

## 待讨论的问题：

---

- 样本集决定了下届
- 样本集与模型决定了上届
- 样本集确立特征扩充上届
- GAN模型是对上届的逼近

## 6.8

---

### 提出问题：

GAN-like数据增强方法在什么条件下是有效的，如何量化和着眼于特征定义数据增强有效性。

how to chose gan model?

### 难点：

特征（语义信息）的评价难以直接量化，现有方法如IS，FID等都有局限性，从原理上不能评价特征扩充的效果。

### 方法：

通过建立语义空间到隐空间的映射，使得隐空间的拓扑性质与语义空间的特征性质相对应，由此能够通过隐空间性质的度量，代表语义信息的度量。

### 前提假设：

隐空间与语义空间的对应（一个大问题），结论为现存实验证明一些GAN网络能够有效满足这个前提。因此我们寻找的隐空间与语义空间的映射是存在的。

- 隐空间解耦性
- 隐空间的线性
- 隐空间凸性

### 方法：

- 对于两个预训练的生成器网络A，B
- 寻找映射f, 将A，B映射到**公共中间隐空间W**。
- 验证A，B到W的映射皆满足前提假设中提所出的性质。
- 在**公共中间隐空间W**中选择比较分布的距离

## 5.26

---

## 提出问题：

GAN-like数据增强方法在什么条件下是有效的，如何量化和着眼于特征定义数据增强有效性。

how to chose gan model?

## 难点：

特征（语义信息）的评价难以直接量化，现有方法如IS，FID等都有局限性，从原理上不能评价特征扩充的效果。

## 方法：

通过建立语义空间到隐空间的映射，使得隐空间的拓扑性质与语义空间的特征性质相对性，由此能够通过隐空间性质的度量代表语义信息的度量。

## 前提假设：

隐空间与语义空间的对应（一个大问题），结论为现存实验证明一些GAN网络能够有效满足这个前提。因此我们寻找的隐空间与语义空间的映射是存在的。

- 隐空间解耦性
- 隐空间的线性
- 隐空间凸性

## 方法：

- 对于两个预训练的生成器网络A，B
- 寻找映射f,将A，B映射到**公共中间隐空间W**。
- 验证A，B到W的映射皆满足前提假设中提所出的性质。
- 在**公共中间隐空间W**中选择比较分布的距离

## 结果：

对比不同GAN模型的特征扩充指标，stylegan等优于naïve GAN

## 结论：

探讨了

A universal evaluation approach for gan-based data augmentation effe

how good is my GAN:

evaluation method from latent space

- relate to the original data set (data distribution)

- relate to both the dataset and the GAN algorithm (same GAN behave differently on different dataset?)
- 有效性：真的是特征？怎么说明特征扩充。  
传统：模拟投影呈现过程  
GAN：模拟分布过程

latent space , evaluation method for feature augmentation( data augmentation) , for GAN, evaluation metrics,

## Criteria on evaluation of GAN-based data augmentation

### 摘要

目的：评价GAN方法在数据扩征的有效性，量化评价GAN对样本特征的扩征能力。

方法：探讨隐空间的性质，提出在隐空间内有效评价语义扩充的条件，揭示GAN对样本特征扩充的物理本质（摄影几何vs分布拟合）；分析验证GAN-like方法隐空间的性质与语义扩充评价条件，提出对GAN-like网络建立公共隐空间的方法（验证公共隐空间的性质）；解决了OT距离的存在性，提出了解析解，确立公共隐空间中的特征扩充评价指标（测度metrics）；

结果：对不同类型的GAN测试了评价模型与评价指标，分析的风差异（性能差异）与传统的评价模型做对比。

结论：探讨了隐空间的性质，有效评价与以扩充的条件，提出了在隐空间中评价特征扩充的评价指标。

指导在数据增强上GAN的选择，并且

## 待讨论的问题：

- 样本集决定了下届
- 样本集与模型决定了上届
- 样本集确立特征扩充上届
- GAN模型是对上届的逼近

discussion：通过pretrained 模型方式，认为隐空间的特征同时反映了算法结构与数据集的结构。隐空间是数据的也是算法的。

measures latent space



## 突破点：

- 隐空间与语义空间的对应（问题定义，验证，解决方案）
- 寻找映射 $f$ ，将 $A$ ， $B$ 映射到 **公共中间隐空间**  $m$ ：隐空间 对于不同的网络是不同的

stylegan  $\rightarrow$  w space  $\rightarrow$   $m$  (编码)

gan  $\rightarrow$  naive latent space  $\rightarrow$   $m$  (编码)

增强方法： AutoAugement

方法：探讨隐空间的性质（系统框架，基础：结构性，线性，徒刑），提出在隐空间内有效评价语义扩充的条件，揭示GAN对样本特征扩充的物理本质（摄影几何vs分布拟合）；分析验证GAN-like方法隐空间的性质与语义扩充评价条件（性质的量化评价），提出对GAN-like网络建立公共隐空间的方法（验证公共隐空间的性质：寻找映射 $f$ ，将 $A$ ， $B$ 映射到 **公共中间隐空间**  $m$ ：隐空间 对于不同的网络是不同的 stylegan  $\rightarrow$  w space  $\rightarrow$   $m$  (编码)， gan  $\rightarrow$  naive latent space  $\rightarrow$   $m$  (编码))；解决了OT距离的存在性，提出了解析解，确立公共隐空间中的特征扩充评价指标（测度metrics）；

结果：对不同类型的GAN测试了评价模型与评价指标，分析的风差异（性能差异）与传统的评价模型做对比。T-SNE method 可视化了公共隐空间的数据分布。

结论：探讨了隐空间的性质，有效评价与以扩充的条件，提出了在隐空间中评价特征扩充的评价指标。

字问题： attribute editing，几何与材质属性分离。

## 5.19

---

## 提出问题：

数据增强必要性，GANlike算法 广泛应用：1、domain shift 2、style editing (transfer)

对传统数据增强方式扩充（旋转等等）。

Problem：但是样本扩充的机制与有效性不明确。

目标：基于gan的方法，分析方法框架，评价模型

## 分析问题：

- 原始GAN的基本原理（博弈训练），Gan的变种，cgan, stylegan, PGgan（训练方式），wgan 损失函数。
- 数学原理(最优传输)，隐空间、可编辑属性，传输机制（domain shift），生成分布的描述。
- 生成数据的分布表征。（特征评价）

## 解决问题，目的：

- 模式崩溃问题——更多的特征(OT)
- 寻求更好的解耦性——特征单独操控编辑的基础
- 在隐空间中寻找改变特征的方向（SVM）——特征单独操控编辑的工程方案
- 生成数据的分布表征：GAN-inversion ——在隐空间中表示生成样本分布
- 评价模型：OT ——量化评价特征扩充

## 方法：

- 不同层次特征的分离 （特征的分离，stylegan—mixing）
- 单独操控 （单独操纵：解耦性、如何寻找，分类网络，提取特征，做标记，svm 特征方向）
- 混合 （需要多少参数：去控制一个特征, stylegan）
- 扩充的效果 （ inversion, OT, 解析解的话，写成解析loss function? ）

## 结果：

不同gan的量化度量结果。

结构性、model、内插与外插的概念。

## 结论：

以隐空间的解耦性为基础，通过特征分离和特征

**在隐空间有良好解耦性（量化方式可以采用SVM）的条件下，采用gan-based特征分离与特征操控的方法，可以实现高效的样本扩征。**

良好的解耦性， gan-based 特征分离与特征操控 实现扩充

## 目标题名：

efficient data augementation gan-like

edittable attribute for efficient data augementation with gan like approach

measurable

measurable data augementation method

effective

feature expolation

expansion method with

##

---

## 在隐空间中描述问题

- 有效扩充——外插（隐空间的向量）——新的特征？（特征的强度？**特征的混合？**）——>
- 无效扩充——内插（隐空间的向量），属性编辑——特征的平滑过渡，不同特征的分离——>特征，线性（能不能做好——解耦问题）
- 不同层级的特征

问题：隐空间能代表特征空间吗？

判断标准：语义空间

操作空间：隐空间 能有效改变 语义空间？

原始GAN: 做分布的拟合，内插，分布的拟合问题，比原始gan好, GAN, W-GAN的解析解？

stylegan: 学的东西不一样，学的比原始gan要好。

提出问题：GAN-like方法在什么条件下是有效的。

比较GAN: styleGAN:不同网络的特征有效特征扩充效果

假设：隐空间与语义空间的对应性

对应性，解耦性部分重合

- 至，

方法：

- 隐空间评价模型
- 映射到隐空间
- 隐空间比较分布传输距离

结果：

- 数值

结论：

- 给出了GAN特征扩充的评价

两条路径：样本增强的方法 样本增强的评价